

PTQ 기반 INT4 모델의 정확도 회복을 위한 출력단 보정 기법

Output Correction for Accuracy Recovery in PTQ-Based INT4 Models

요약

Post-Training Quantization(PTQ)은 추가적인 학습 없이도 모델을 경량화할 수 있어, 모바일 및 엣지 환경에서의 딥러닝 모델 활용성을 높인다. 그러나 INT4 수준의 낮은 정밀도로 weight와 activation을 양자화할 경우, 모델 성능이 심각하게 저하되는 문제가 발생한다. 본 연구는 이러한 성능 저하의 주요 원인을 출력 단계에서의 예측 값 왜곡, 즉 logit 수준의 양자화 오차로 보고, 이를 보정하기 위한 후처리 네트워크(denoising module)를 제안한다. 제안된 모듈은 기존 모델의 FC layer와 softmax 사이에 Linear Layer를 삽입하는 방식으로 구성되며, 원본 label을 활용한 Cross-Entropy Loss를 통해 학습된다. ResNet-110 기반의 INT4 양자화 모델을 대상으로 두 가지 구조의 denoising module을 설계하고 성능을 비교한 결과, 출력단에 위치한 경량 MLP 기반 후처리 네트워크가 효과적으로 성능을 복원함을 확인하였다. 또한 layer 수와 hidden dimension에 따른 성능-자원 효율성 간 trade-off를 실증하였다. CIFAR-10 데이터셋 기반의 실험에서, 제안된 구조를 적용한 양자화 모델은 최대 6.65%p의 정확도 향상을 보였다.

1. 서론

딥러닝 모델은 이미지 인식, 자연어 처리 등 다양한 분야에서 핵심 기술로 자리 잡았으나, 막대한 계산량과 파라미터 수로 인해 모바일, IoT, 엣지 디바이스와 같은 자원 제약적인 환경에 배포하기 어렵다는 한계가 있다 [1]. 이를 해결하기 위한 방법 중 하나인 Post-Training Quantization(PTQ)은 사전 학습된 모델의 가중치와 활성화 값을 정수 형태로 변환하여 메모리 사용량과 연산 복잡도를 줄이는 기술이다 [2]. 기존 학습에 사용된 거대 데이터셋을 요구하지 않으며, calibration을 위한 일부의 데이터셋만 필요해 학습 및 데이터 관점에서 매우 높은 효율성을 가진다. 하지만 PTQ를 INT4 수준으로 극단적으로 적용할 경우, 모델 정밀도가 크게 저하되어 예측 정확도가 심각하게 하락할 수 있다. 실제로 본 연구에서 사용한 ResNet-110 모델의 경우, FP32 정확도는 93.81%지만 INT4 양자화 시 81.20%로 약 12.6%p 감소하는 결과를 보였다.

기존의 연구들은 양자화 과정 자체를 개선하거나 [3,4], 모델 내부의 가중치 또는 활성화 값 분포를 정밀하게 조정하는 데 초점을 맞추어 왔다 [5,6]. 이러한 방식들은 양자화로 인한 국소적인 오차를 줄이는 데는 효과적일 수 있으나, 네트워크 전반을 거치며 누적되는 오차, 특히 최종 예측에 직접적인 영향을 미치는 오차를 제어하는 데에는 한계가 있다. 이에 본 연구는 INT4와 같은 극단적인 양자화로 인해 발생하는 logit 단계의 예측 오류를 보정 대상으로 삼고, 사전 학습 및 양자화된 모델의 마지막 FC layer와 softmax 사이에 '후처리 네트워크'를 삽입하는 방식을 제안한다. 후처리 네트워크는 Linear layer로 구성되며, 다양한 구조와의 비교 실험을 통해 해당 구성의 효과성을 정량적으로 분석하였다. 그 결과, 제안된 방식은 ResNet-110 모델의 INT4 양자화 정확도를 기존 81.20%에서 87.85%까지 복원하여, 심각한 정확도 저하 문제를 효과적으로 완화할 수 있음을 확인하였다. 따라서 본 논문의 주요 기여 항목은 다음과 같다.

- PTQ 기반 양자화 모델의 양자화 오류를 감소시키는 보조/후처리 네트워크를 통한 새로운 접근법 제시
- 보조/후처리 네트워크가 양자화 오류에 미치는 영향 분석
- 본 방법론을 적용한 INT4 양자화 모델의 유의미한 성능 향상 달성

2. 관련 연구

2.1 Post-Training Quantization(PTQ)

Post-Training Quantization은 학습 완료된 신경망의 weight와 activation을 정수 형태로 변환하는 방식으로, 추가 학습 없이 모델을 경량화할 수 있다는 장점이 있다. 대표적으로 AdaRound [3], QDrop [4]와 같은 기법들이 있으며, 이들은 주로 양자화 시 발생하는 오차를 줄이기 위해 rounding, calibration 등의 전략을 활용한다. 특히 uniform quantization 기반의 PTQ는 구현이 간단하고 하드웨어 친화적이라는 장점이 있어 널리 활용되고 있다.

하지만 대부분의 PTQ 기법은 내부 연산의 정확도를 유지하는데 초점을 맞추며, 최종 출력단에서 발생하는 오차를 직접적으로 보정하는 연구는 상대적으로 드물다. INT4와 같이 매우 낮은 비트폭에서는 미세한 정보 손실이 누적되어, softmax 입력에 해당하는 logit 자체가 왜곡되며, 이는 직접적인 품질 저하로 이어진다.

이러한 한계를 극복하기 위해 일부 연구는 PTQ 기법에 다양한 보조 전략을 통합하여 정밀도 손실을 줄이고자 했다. 예를 들어, Banner et al.은 INT4 수준의 post-training quantization에서 정확도 저하를 최소화하기 위한 실험을 수행하였으며 [5], Park et al.은 FLOPs-aware 관점에서 최적의 비트폭 할당을 통해 효율성과 정확도 사이의 균형을 달성하려 했다 [6]. 또한, Choi et al.은 pruning, low-rank approximation, knowledge distillation을 통합한 범용 신경망 압축 프레임워크를 제안하여 다양한 하드웨어 제약 환경에 적응 가능한 압축 전략을 탐색하였다 [7].

2.2 Denoising 기반 보정 기법

양자화로 인한 모델의 출력 오류를 정제하는 접근은 일부 distillation 기반 연구에서도 찾아볼 수 있으나, 대부분은 feature-level 정렬이나 soft label imitation에 그친다. 예를 들어, Knowledge Distillation은 teacher와 student 모델의 logit을 정렬하거나 feature map을 직접 모방하게 하여 성능을 개선한다. 하지만 이들 기법은 양자화 환경에 직접적으로 대응하거나 출력값의 정제를 목적으로 하지는 않는다.

한편, 최근에는 PTQ 이후 별도의 보조 네트워크를 추가하여 정제 성능을 높이려는 시도가 이루어지고 있으며, 본 연구는 이러한




그림 1. Denoising Module을 통한 양자화 오류 개선 프레임워크

흐름에 맞춰 logit 보정에 특화된 경량 후처리 구조를 설계하였다. 기존 연구들이 대부분 feature 수준에서 clipping 또는 calibration을 통해 간접적으로 성능 향상을 시도했다면, 본 연구는 출력단에서 직접 정제 연산을 수행함으로써 보다 직관적이고 효과적인 오차 보정 방법을 제안한다는 점에서 차별성을 갖는다.

3. 제안 방법

3.1 전체 구조 개요

본 논문에서는 INT4로 양자화된 ResNet-110 모델의 성능 저하 문제를 해결하기 위해, 두 종류의 denoising module을 설계하고 이들의 효과를 비교 분석하였다. 이때 denoising module에 대한 학습이 진행되는 동안 denoising module 외의 모든 layer는 freeze된다. 그림 1에서 확인할 수 있는 전체 구조는 다음과 같이 구성된다.

- Base Model: Resnet-110 구조에 대해 weight와 activation을 INT4로 양자화한 모델
- Denoising Module 1: ResNet의 avg pooling layer 이전에 위치한 conv2d 기반 보조 네트워크. INT4에서의 feature map이 FP32에서의 feature map과 동일해지는 것을 목표로 삼으며, MSE loss function을 사용한다.
- Denoising Module 2: FC layer와 softmax 사이에 삽입되는 MLP 구조의 후처리 네트워크. INT4에서의 logit vector가 원본 label을 맞추도록 목표로 삼으며, Cross-Entropy loss function을 사용한다.

3.2 Denoising Module 1: Feature-Level 정제

Denoising module 1은 ResNet의 마지막 residual block과 avg pooling 사이에 삽입되며, conv2d 연산 기반의 구조를 가진다. 이 표 1. ResNet-110 모델의 양자화 수준에 따른 Acc@1 정확도

양자화 수준	FP32	INT8	INT6	INT4
Accuracy	93.81%	93.82%	93.37%	81.20%

모듈의 출력은 INT4로 양자화되어 avg pooling layer로 전달된다. 학습 시에는 ResNet-110 FP32 모델의 동일 위치 feature map을

target으로 하여 Mean Squared Error(MSE) 손실을 최소화하도록 학습하였다. 이때, backbone의 모든 ResNet block은 freeze 상태로 유지되었으며, 보조 네트워크만 학습되었다.

실험 결과, 학습 초기의 MSE는 0.57 수준에서 시작하여 최종적으로 0.42까지 감소하였다. 하지만 전체 모델의 정확도에는 의미 있는 개선이 나타나지 않았으며, 이후 module 1 없이 module 2만을 사용한 경우 오히려 성능이 소폭 향상되었다. 이로부터 feature-level에서의 양자화 오차는 비교적 적으며, 주된 성능 저하는 출력단에서 발생함을 추정할 수 있다.

3.3 Denoising Module 2: Logit-Level 정제

Denoising module 2는 FC layer의 출력을 입력으로 받아, softmax 이전의 logit을 보정하는 경량 MLP 구조로 설계되었다. 입력과 출력은 모두 CIFAR-10 분류를 위한 10차원이며, 중간 hidden layer의 수와 차원을 다양하게 실험하였다.

모듈 외의 모든 layer는 freeze 상태로 유지되며, 학습은 SGD optimizer(momentum=0.9, weight_decay=1e-4), learning rate 0.1, MultiStepLR([100,150], gamma=0.1), 총 200 epoch 설정으로 수행되었다. 초기에는 KL divergence, CE, KL+CE 조합에 대한 실험을 진행하였고, 각 정확도는 87.45%, 87.46%, 87.50%로 큰 차이가 없음을 확인하였다. 이에 따라 연산량을 고려해 최종적으로 CE loss만 사용하였다.

4. 실험 및 결과

4.1 실험 설정

실험은 CIFAR-10 데이터셋을 기반으로 진행되었으며, 학습 시 정규화 및 데이터 증강을 적용하였다. 모델 구조는 ResNet-110이며,

표 2. Denoising module 1과 2의 결합 여부 및 loss function에 따른 정확도 비교

	Denoising Module 1	Denoising Module 2	Acc@1 Accuracy
Case 1.	미사용	미사용	81.20%
Case 2.	Conv2d	미사용	82.37%

	MSE Loss		
Case 3.	미사용	MLP CE Loss	87.46%
Case 4.	Conv2d MSE Loss	MLP CE Loss	87.36%

INT4 양자화를 통해 weight와 activation 모두를 정수화하였다. 양자화 방식은 uniform PTQ 방식으로 진행되었으며, denoising module에는 양자화를 적용하지 않았다. 표 1의 결과처럼, INT4 적용 시의 급격한 정확도 하락을 보정하기 위해 제안한 두 denoising module 구조를 실험적으로 비교하였다.

Denoising module 1은 64개의 커널을 갖는 3x3 커널 크기의 convolution layer를 사용하였으며, 입력과 출력 크기를 일치시키기 위해 stride=1 및 zero padding을 사용하였다. Denoising module 2는 10→20→10의 형태를 갖는 linear layer를 사용하였다.

4.2 Denoising Module 1 VS 2: 각 모듈의 효과 비교

ResNet block을 freeze한 상태로, module 1은 feature map을 FP32 teacher의 값과 정렬하는 방식으로 학습되었다. 초기 MSE는 0.572에서 시작하여 최종 0.427까지 감소하였으나, 실제 정확도 향상에는 유의미하게 기여하지 못했다. 표 2에서 확인할 수 있듯이, module 1을 사용한 경우 미미한 성능 향상을 확인할 수 있었고, module 2를 사용했을 때 성능이 큰 폭으로 향상되었다. 다만 두 모듈을 모두 사용했을 때, 정확도가 미세하게 하락하는 모습을 보여, 주된 양자화 오차는 출력단(logit)에서 발생함을 시사한다.

4.3 Denoising Module 2의 구조 설계 탐색

다양한 layer 깊이 및 hidden node 수를 가지는 구조에 대해 성능을 비교하였다. 표 3의 결과대로, layer 수 또는 노드 수를 단순히 늘리는 방식은 일정 수준 이후 성능 향상에 기여하지 않음을 확인하였다. 특히 10→10x3→10 및 10→20→40→20→10과 같은 중간 복잡도 구조가 성능-자원 효율성 측면에서 가장 우수한 균형을 제공하였다.

5. 결론 및 향후 연구

본 논문에서는 INT4로 양자화된 딥러닝 모델에서 발생하는 정확도 저하 문제를 해결하기 위해, 출력 정제용 경량 보조 네트워크(denoising module)를 제안하였다. 기존의 양자화 보정 기법들이 내부 feature 또는 weight 중심의 조정에 집중해 온 것과 달리, 본 연구는 softmax 이전 logit을 정제하는 후처리 기반 접근법을 제시하였다는 점에서 차별성을 가진다.

ResNet-110 모델과 CIFAR-10 데이터셋을 기반으로 한 실험을 통해, feature-level 정제용 module 1은 정확도 향상에 크게 기여하지 못했으며, 반면 logit-level 정제를 수행하는 module 2는 최대 87.85%의 정확도를 달성하며 INT4 기준 성능을 약 6.65%p 향상시켰다. 이는 주된 양자화 오차가 출력단에서 발생한다는 가설을 뒷받침하며, 성능 복원에 있어 logit 정제 방식의 타당성을 입증한

표 3. Denoising module 2의 구조 유형 별
파라미터 수 및 정확도 비교

각 레이어 별 Node 수	구조 유형	파라미터 수	Acc@1 Accuracy
10→5→10	Simple	125	84.71%
10→10→10	Shallow	240	87.52%

10→20→10	Shallow, Wide	470	87.46%
10→10x3→10	Moderate	630	87.78%
10→10x9→10	Deeper	1,410	87.39%
10→20→40 →20→10	Wider	2,250	87.85%
10→20→40→80 →40→20→10	Deep, Widest	9,010	87.72%

다. 또한 다양한 구조를 실험함으로써, layer 수와 hidden node 수를 무작정 늘리는 것이 성능 향상으로 이루어지지 않음을 확인하였다.

본 연구는 PTQ 이후 손실된 표현력을 복구하는 새로운 설계 방향을 제시하며, 다음과 같은 확장 가능성을 지닌다.

- 보조 네트워크 자체의 양자화 및 추가 압축
- 다양한 비전.자연어처리 모델로의 일반화 실험

따라서 향후 연구에서 보조 네트워크의 양자화를 통해 완전한 양자화를 달성하고 앞서 유의미한 성능을 보이지 못했던 feature-level 정제용 module 1에 대해 유의미한 성능을 내도록 하는 추가적인 연구에 대한 필요성이 존재한다. 궁극적으로 ResNet 모델 뿐만이 아닌 다양한 종류의 모델에 대한 적용 가능성을 검토하고 CIFAR-10 외의 다양한 데이터셋에 대한 범용성을 더 늘릴 수 있도록 하는 추가적인 탐색이 필요하다.

참고 문헌

- [1] G. Menghani, "Efficient Deep Learning: A Survey on Making Deep Learning Models Smaller, Faster, and Better," ACM, 2023.
- [2] M. Nagel, M. Fournarakis, R. A. Amjad, Y. Bondarenko, M. Van Baalen, T. Blankevoort, "A White Paper on Neural Network Quantization," arXiv preprint arXiv:2106.08295, 2021.
- [3] M. Nagel, M. van Baalen, T. Blankevoort, and M. Welling, "Up or Down? Adaptive Rounding for Post-Training Quantization," ICMR, 2020.
- [4] C. Shen, M. Zhang, L. Zhang, and Y. Wang, "QDrop: Randomly Dropping Quantization for Extremely Low-bit Post-training Quantization," CVPR, 2022.
- [5] S. Banner, A. Hubara, E. Hoffer, and D. Soudry, "Post-training 4-bit quantization of convolutional networks for rapid-deployment," NeurIPS, 2019.
- [6] S. Park, S. Lee, D. Yoon, and W. Sung, "FLOPs-aware quantization for accurate and efficient neural networks," AAAI, 2021.
- [7] Y. Choi, M. El-Khamy, and J. Lee, "Universal Deep Neural Network Compression," IEEE Transactions on Neural Networks and Learning Systems, 2022.